TRABAJO 1 – IMPLEMENTACIÓN DATALAKE AWS

SANTIAGO ALBERTO MORENO QUEVEDO DANIEL GARCÍA GARCÍA PROFESOR: EDWIN MONTOYA

ALMACENAMIENTO Y RECUPERACIÓN DE LA INFORMACIÓN

UNIVERSIDAD EAFIT

MEDELLÍN – ANTIOQUIA

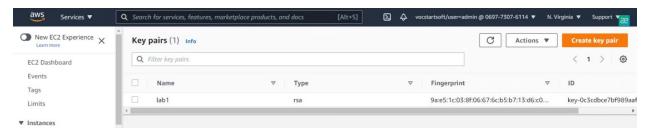
2021 - 2

Tabla de Contenido

Implementación del Datalake	3
EC2 Key Pair	
Creación del bucket S3	3
Particionamiento y zonas del datalake	5
Subida de archivos al datalake	7
Cambio de políticas del bucket	11
Creación de primer Crawler	11
Query de prueba en Athena	13
Procesos ETL y Crawlers con Glue	14
Consultas en Athena	21
Creación del EMR	23
Consultas con Hive	25

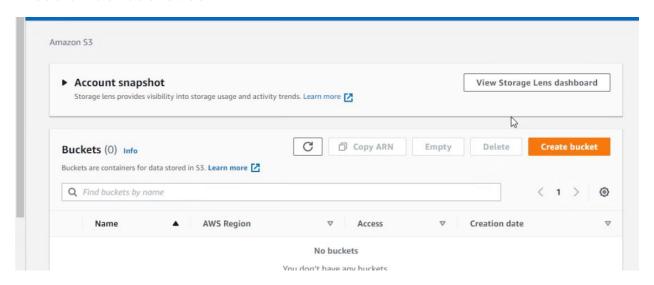
Implementación del Datalake

EC2 Key Pair



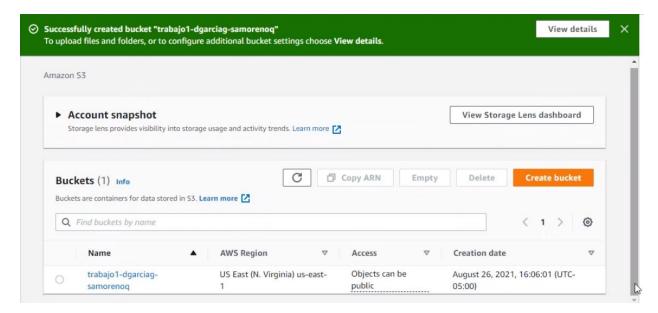
Primeros debemos crear una Key Pair en AWS EC2 que usaremos posteriormente en la creación de los diferentes elementos que nos proporciona AWS para implementar un datalake.

Creación del bucket S3



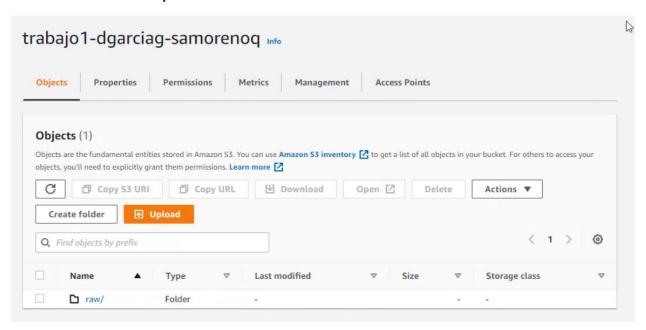
azon S3 > Create bucket	
reate bucket Info	
kets are containers for data stored in S3. Learn more 🖸	
General configuration	
Bucket name	
trabajo1-dgarciag-samorenod	
Bucket name must be unique and must not contain spaces duppercase letters. See rules for bucket naming 🖸	
AWS Region	
US East (N. Virginia) us-east-1 ▼	
Copy settings from existing bucket - optional	
Only the bucket settings in the following configuration are copied.	

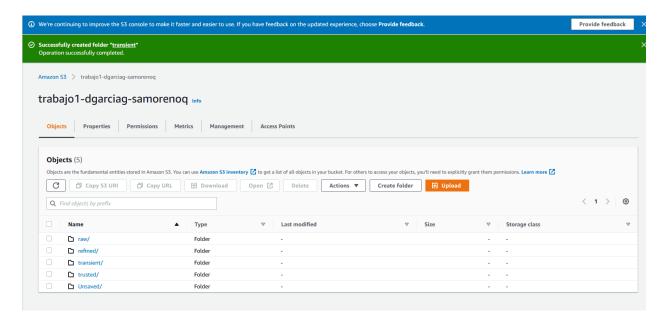
Block Public Access settings for this bucket Public access is granted to buckets and objects through access control lists (ACLs), bucket policies, access point policies, or all. In order to ensure that public access to this bucket and its objects is blocked, turn on Block all public access. These settings apply only to this bucket and its access points. AWS recommends that you turn on Block all public access, but before applying any of these settings, ensure that your applications will work correctly without public access. If you require some level of public access to this bucket or objects within, you can customize the individual settings below to suit your specific storage use cases. Learn more Block all public access Turning this setting on is the same as turning on all four settings below. Each of the following settings are independent of one another. ☐ Block public access to buckets and objects granted through new access control lists (ACLs) S3 will block public access permissions applied to newly added buckets or objects, and prevent the creation of new public access ACLs for existing buckets and objects. This setting doesn't change any existing permissions that allow public access to S3 resources using ACLs. ☐ Block public access to buckets and objects granted through any access control lists (ACLs) S3 will ignore all ACLs that grant public access to buckets and objects. Block public access to buckets and objects granted through new public bucket or access point policies S3 will block new bucket and access point policies that grant public access to buckets and objects. This setting doesn't change any existing policies that allow public access to 53 resources.



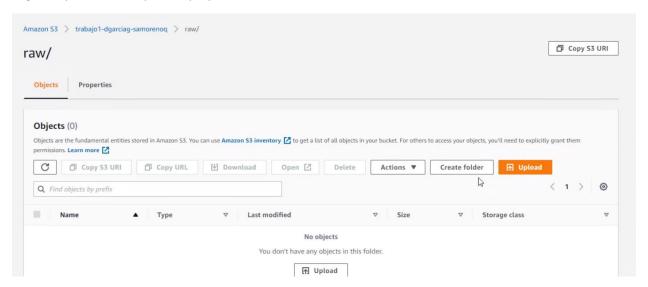
Creamos un bucket en AWS S3 que es el que va funcionar como nuestro datalake para el almacenamiento de los archivos.

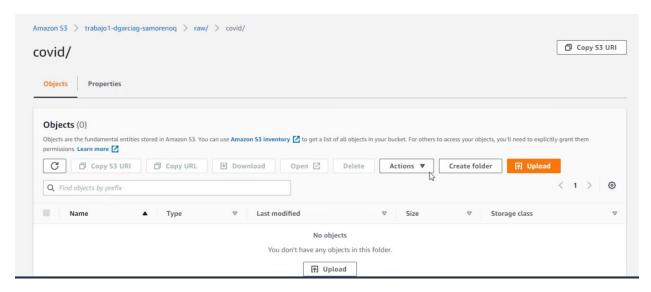
Particionamiento y zonas del datalake





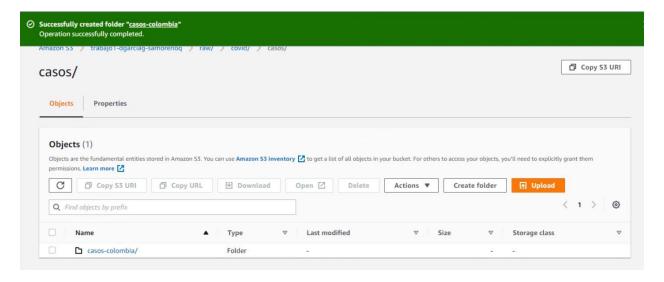
En esta imagen podemos observar las zonas para el datalake donde estarán los diferentes archivos según el proceso ETL que se aplique.

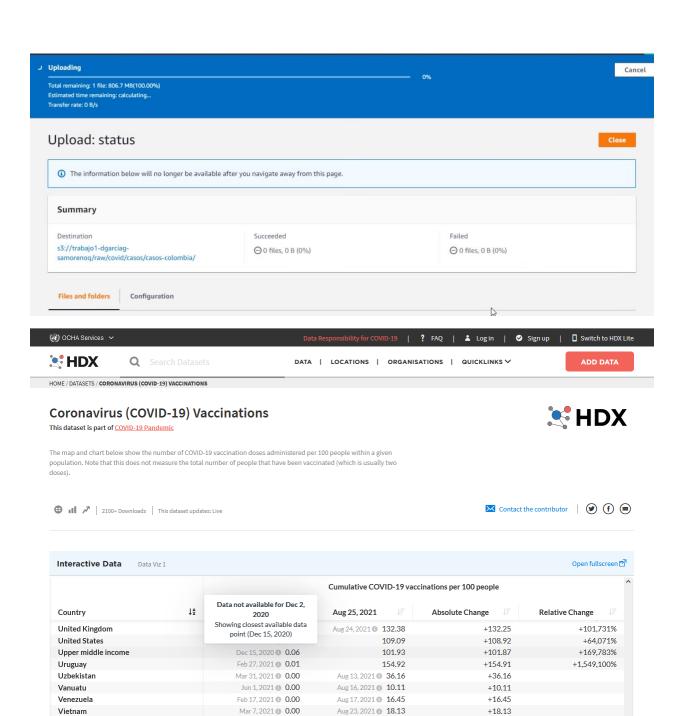




En el directorio de covid creamos las particiones de casos, muertes, vacunaciones y recuperaciones, para su posterior uso en la subida de archivos.

Subida de archivos al datalake





Aug 24, 2021 **142.36**

Aug 23, 2021 **86.04**

Jul 27, 2021 **1.04**

65.15

3.04

26.63

+142.10

+74.60

+65.15

+0.98

+3.04

+26.63

+54,654%

+652%

+1,633%

Aug 25, 2021

Dec 13, 2020 **0 0.26**

Mar 23, 2021 **11.44**

May 9, 2021 **0 0.06**

Apr 14, 2021 **0** 0.00

Feb 18, 2021 **0.00**

0.00

Wales

World

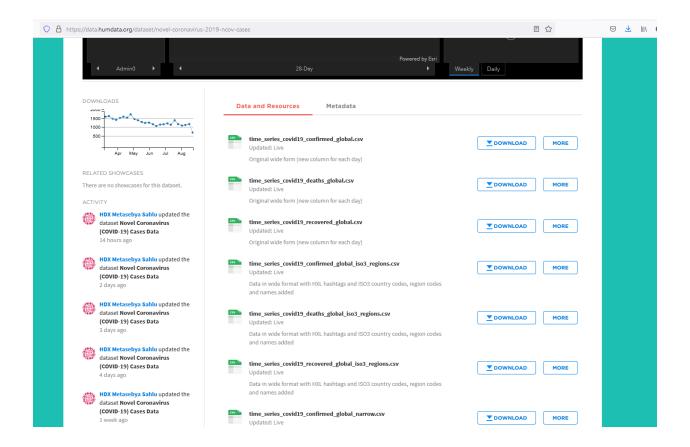
Yemen

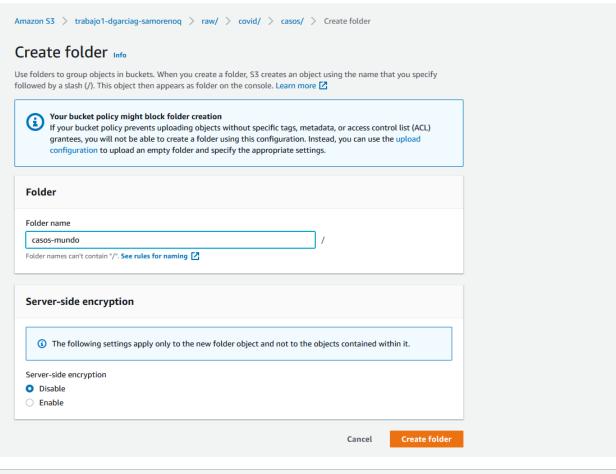
Zambia

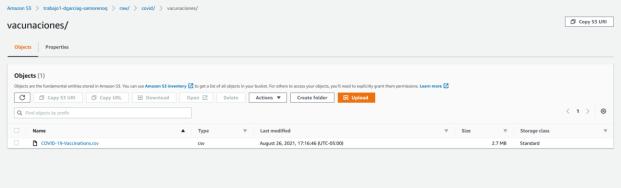
Zimbabwe

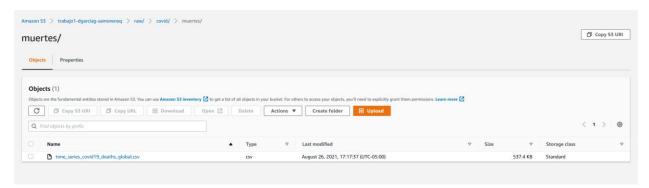
Wallis and Futuna

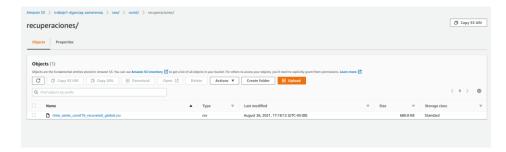
Dec 2, 2020 🔾











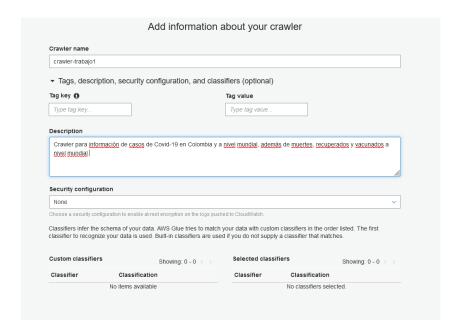
En las anteriores imágenes pudimos observer la carga de todos los archivos con los que vamos a trabajar en el datalake.

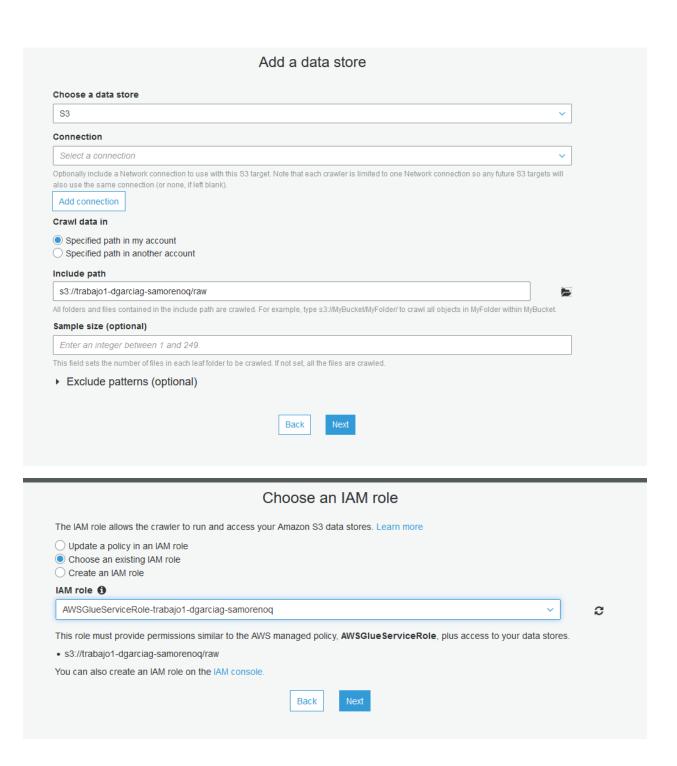
Cambio de políticas del bucket

Cambio de políticas para el bucket para que sea público:

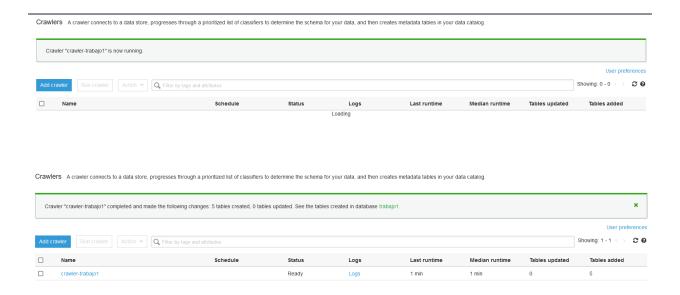


Creación de primer Crawler



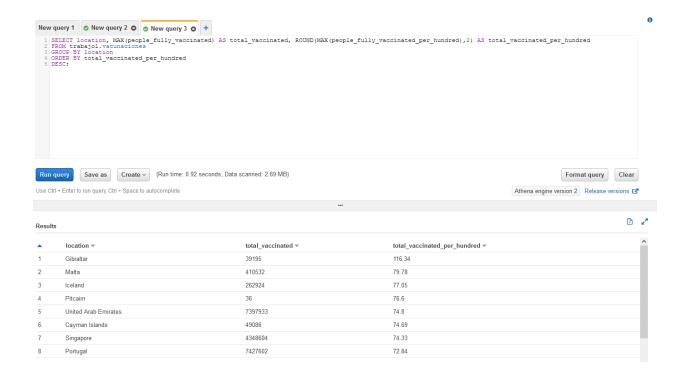


Query de prueba en Athena



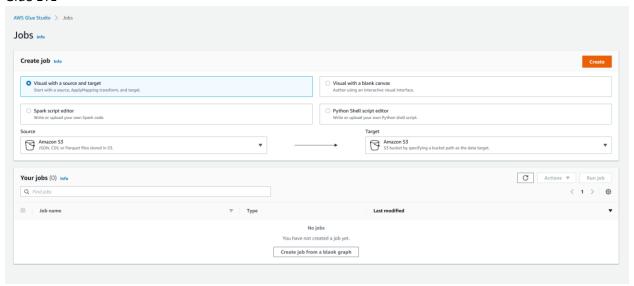
- Query inicial en Raw con Athena

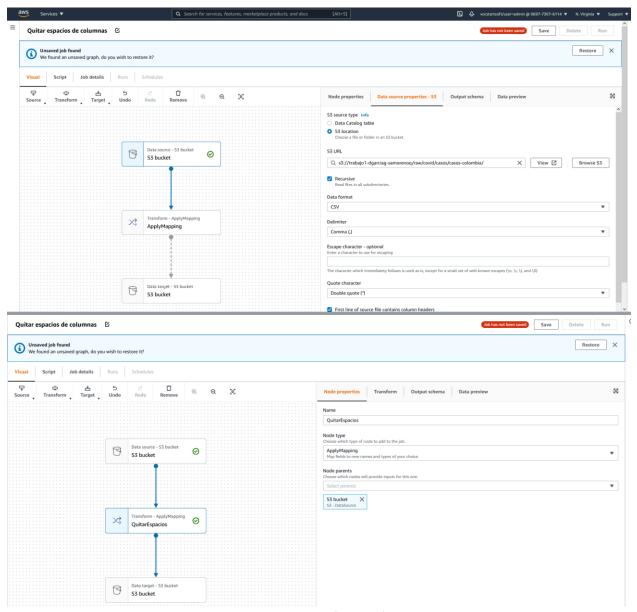
Este query trae el número total de personas vacunadas y de personas vacunadas por cada 100 habitantes por país/región y lo ordena en orden descendente, según el número de personas vacunadas por cada 100 habitantes. Es importante destacar que estos números de vacunados son acumulativos en las tablas originales. Esto quiere decir que en cada fecha, se reporta el número total de vacunados a la fecha, no el número de vacunados nuevos en esa fecha, lo cual quiere decir que en cada fecha, los vacunados son los de la fecha anterior más los que se vacunaron en esa fecha y, por este motivo, se toma la cifra máxima de vacunados en la tabla y no la suma ni la cuenta.



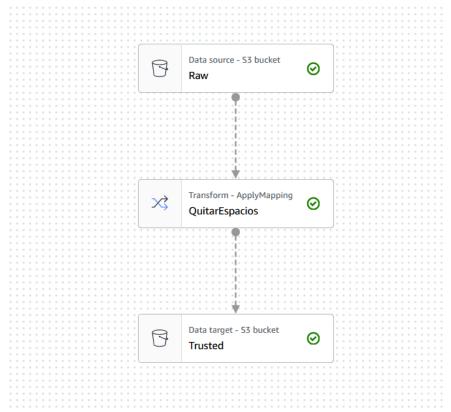
Procesos ETL y Crawlers con Glue

- Glue ETL

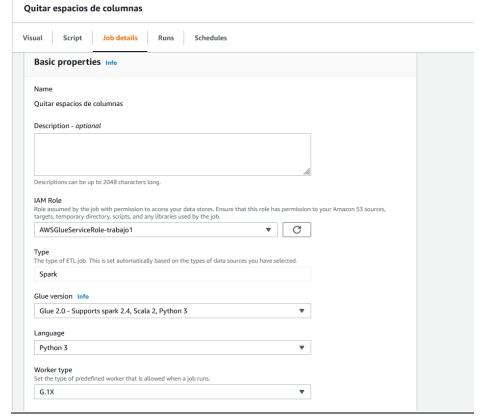




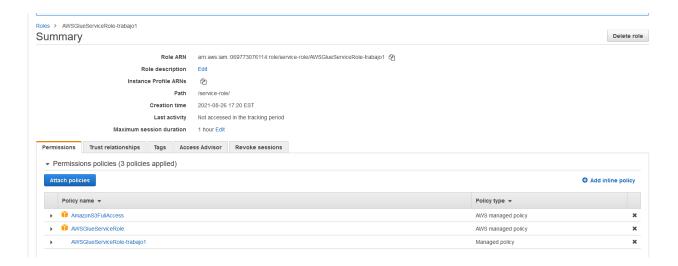
Se quitaron todos los espacios y las tildes en esta transformación.



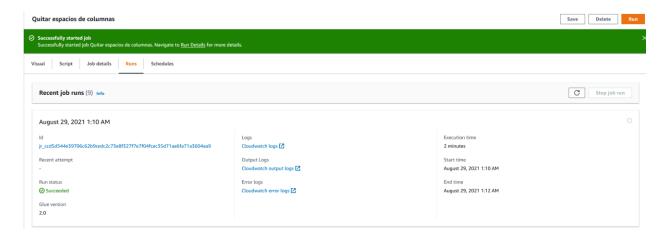
Se guardan los datos transformados en la zona "Trusted".



Propiedades del Job.



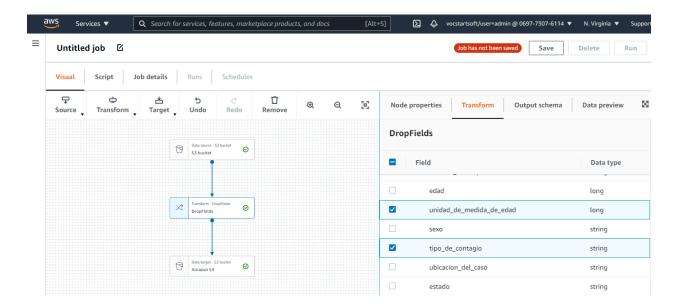
Se agregó AmazonS3FullAccess al rol IAM de Glue.



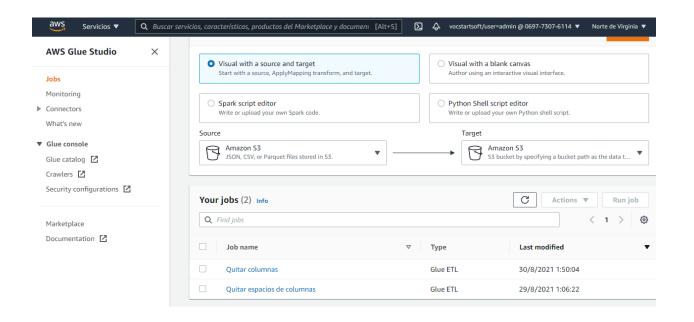
Corrida del Job exitosa.



Nuevo crawler para la zona Trusted.



En un nuevo job eliminamos algunas columnas que para efectos de este trabajo son innecesarias y no nos brindan mucha información. Vamos a recibir la nueva tabla que tenemos en la zona trusted, hacemos la transformación y almacenamos en la zona refined.



Ahora tenemos 2 procesos ETL.

Ejecutar rastreador

Editar

Nombre crawler_trabajo1refined

Descripción

Cree un único esquema para cada ruta de S3 false

Table level

Configuración de seguridad

Etiquetas -Estado Ready

Programación

Last updated Mon Aug 30 01:54:56 GMT-500 2021 **Date created** Mon Aug 30 01:54:56 GMT-500 2021

Base de datos trabajo1refined

Rol de servicio service-role/AWSGlueServiceRole-trabajo1

Clasificadores seleccionados

Almacén de datos S3

Ruta de inclusión s3://trabajo1-dgarciag-samorenoq/refined

Connection

Patrones de exclusión

Crawler para agregar la nueva tabla a la zona refined.

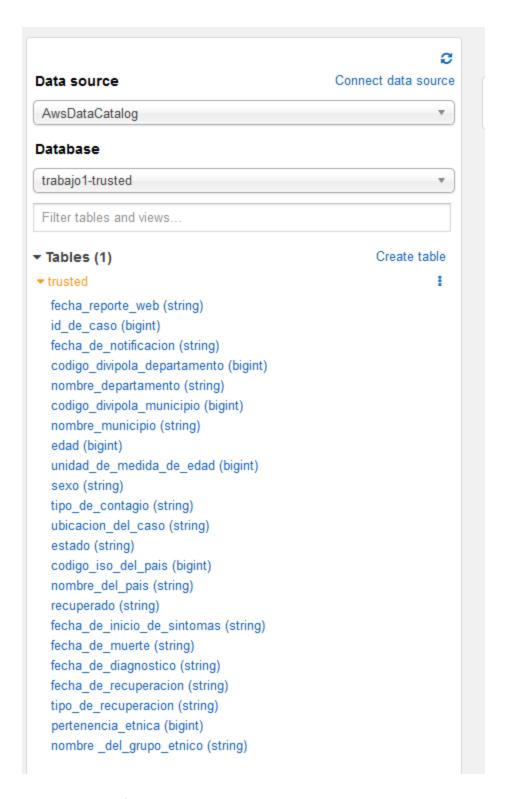
Rastreadores

Un rastreador se conecta a un almacén de datos, avanza por una lista de clasificadores ordenados por prioridad para determinar el esquema de sus datos y, a continuación, crea tablas de metadatos en el catálogo de datos.

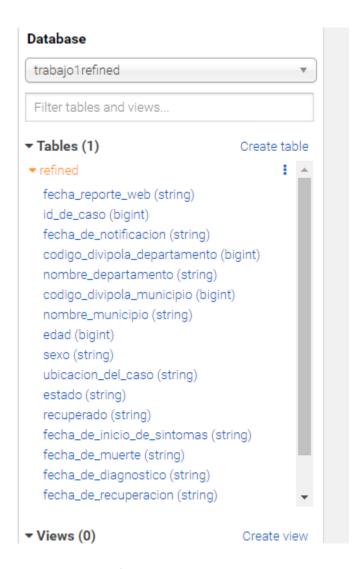
Preferencias del usuario

Mostrando: 1 - 3 < → 🗷 🔞 Añadir un rastreador Ejecutar rastreador Q Filtrar por etiquetas y atributos Tiempo de Última **Tablas** Tablas Nombre Programación Estado Registros eiecución añadidas eiecución actualizadas medio crawler-trabajo1 Ready Registros 1 minuto 1 minuto 0 5 crawler-trabajo1-trusted 0 1 Ready Registros 1 minuto 1 minuto crawler_trabajo1refined Ready Registros 40 segundos 40 segundos 0

Tenemos 3 crawlers en total.

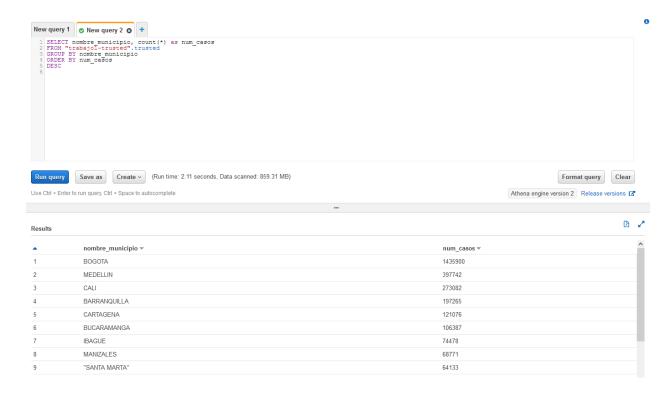


Resultado después del proceso de ETL con Glue y el crawler en trusted: ya las columnas están bien nombradas.

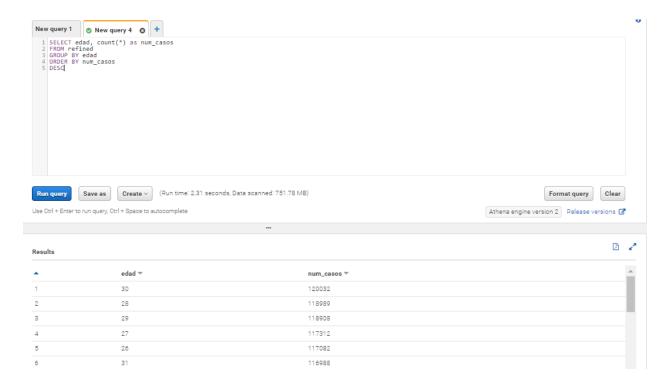


Resultado después del proceso de ETL con Glue y el crawler en refined: ya las columnas están bien nombradas y no tenemos columnas innecesarias como unidad de medida de edad, código iso del país, nombre del país (En cualquiera de los casos estamos hablando de Colombia), tipo de recuperación, etc.

Consultas en Athena



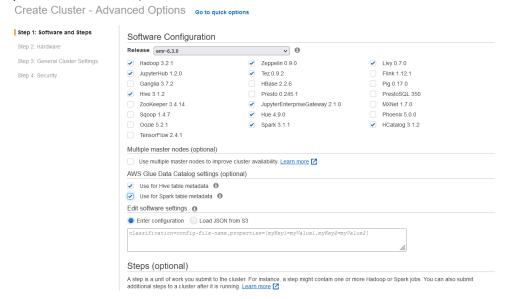
Query en Athena usando los nuevos nombres de columnas.



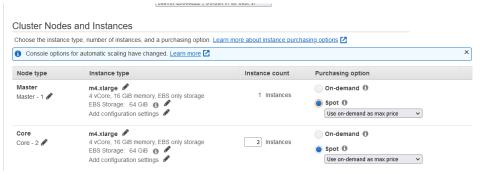
Query en Athena a nuestro archivo en la zona refined, donde podemos observar las edades donde se ha presentado un número mayor de contagios.

Creación del EMR

Elegir las herramientas adecuadas para el cluster. (Nota: en este caso no se usarán todas, pero igualmente es útil porque quedará como plantilla para trabajos futuros en los que sí se usen Spark, notebooks, etc.)



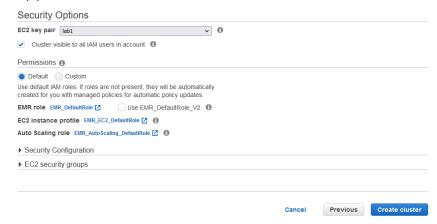
Se escogen los tipos de nodos, que en este caso serán m4.xlarge y se pondrán en Spot para que salga más barato.



Nombre del cluster



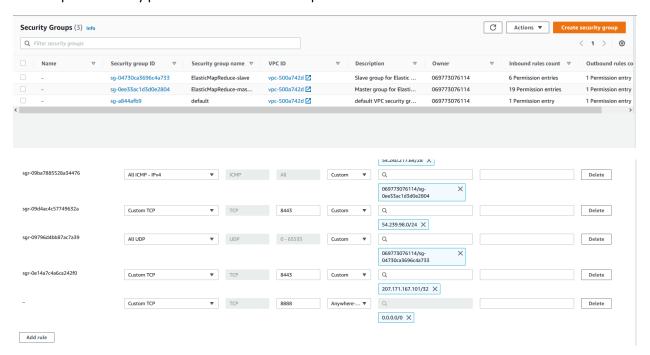
- Key-pair del cluster



- Se debe abrir el puerto 8888 para tener acceso a Hue para hacer las consultas de Hive.

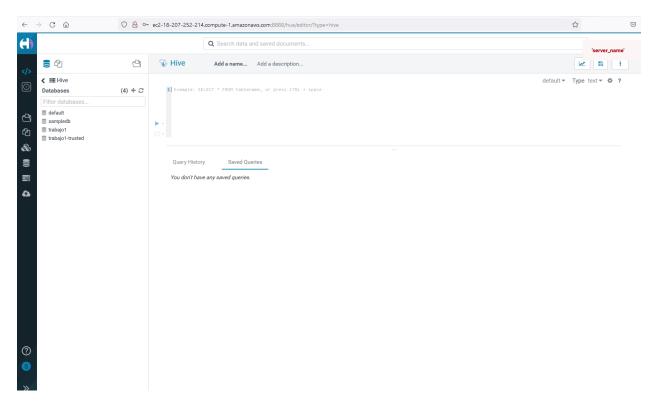


- En security groups, se le cambiarán las inbound rules al nodo maestro del EMR para abrir el puerto 8888 y permitir acceso desde cualquier dirección IP.

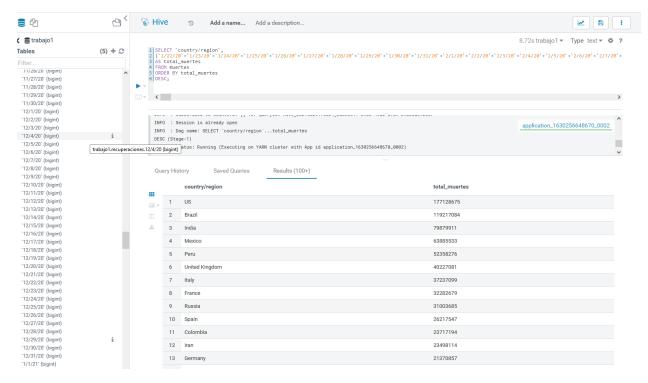


- Ya se tiene acceso a la interfaz gráfica de Hue y se ven las bases de datos creadas por los crawlers.

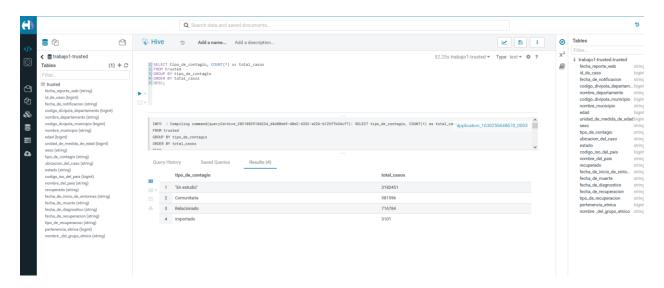
Consultas con Hive



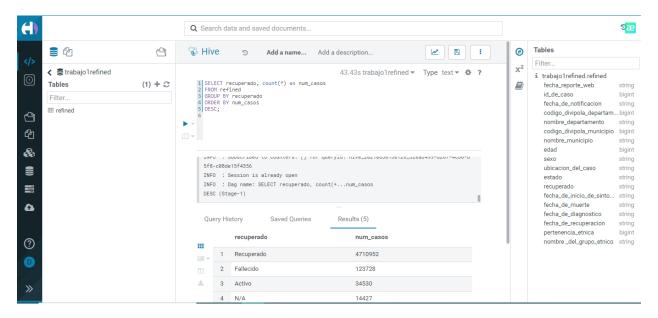
- Ejemplos de consultas en Hive, tanto en la base de datos original como en la modificada en trusted.



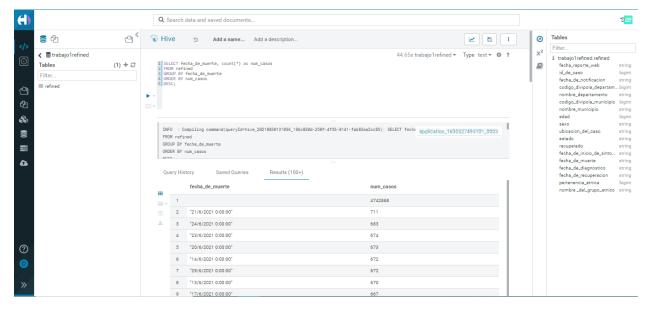
Esta consulta en Hive muestra el número total de muertes por país en orden descendente.



Esta consulta en Hive muestra el número total de casos por cada tipo de contagio. La consulta fue hecha sobre los datos en la zona Trusted, que se obtuvieron tras quitar los espacios en los nombres de las columnas.



Esta consulta se realizó sobre la zona refined, acá podemos observar la cantidad de casos de covid19 que están recuperados, que llevaron a la muerte o que aún están activos, de igual manera, podemos observar que la mayoría de los casos se han recuperado y que hay un número considerable de fallecidos.



Para esta consulta el objetivo era observar las fechas con el mayor número de muertes, podemos ver que el 21 de junio fue la fecha de más muertes, encontrando también que las demás fechas también se encuentran en el mes de junio, por lo que fue el mes más complicado en cuanto a muertes. Esta consulta se realizó también en la zona refined.